AI and Labor Market Mismatch:

Evidence from Matched Vacancy-Applicant Data

Hang Yu [a,b], Hongbo Li [a,b], Dandan Zhang [a,b], Runbo Zhang [a,b], Qiang Li [c]

(a. China Center for Economic Research, Peking University; b. National School of Development, Peking University; c. Zhaopin Limited)

Version: January 2026

Please find the latest version here.

Abstract: This study examines the impact of large language model artificial intelligence (AI-LLM) on labor market mismatches using 1.62 million job applicant records from 2021 to 2025. We construct an occupational AI-LLM exposure index and measures of vertical (education) and horizontal (major) mismatch. Applying a Difference-in-Differences design, we find that while overall mismatch in China's labor market increased, high-AI-LLM-exposure occupations experienced a relative reduction in vertical mismatch following AI shocks like ChatGPT, attributable to clearer demand signals and rising skill requirements. From a job－worker matching perspective, this paper sheds light on the mechanisms through which artificial intelligence influences labor market matching efficiency.

Keywords: Artificial Intelligence; Labor Market Mismatch; Exposure Index

JEL Codes: J24, J31, J62

Summary: This paper examines how the emergence of large language model (LLM)–based artificial intelligence reshapes education mismatch in China's labor market. While a growing literature studies AI exposure and labor demand, far less is known about how generative AI affects *matching efficiency* between workers and jobs. Focusing on education mismatch at the point of job matching, this paper studies whether and how LLM-related technological change alters vertical mismatch (education level misalignment) and horizontal mismatch (field-of-study misalignment).

The analysis combines a task-based LLM exposure index with large-scale online recruitment data from China. Building on task-based approaches in the literature, the paper constructs an occupation-level LLM exposure measure using pre-2021 job postings, thereby mitigating reverse causality from post-LLM job redesign. It then links

this exposure measure to job–applicant matching data from a major recruitment platform, which records both applications and employer responses. This structure allows mismatch to be measured not only among applicants, but specifically among *near-hires*, proxied by applications receiving positive replies.

Descriptive evidence shows that both vertical and horizontal education mismatch are high and increasing over time. Notably, this trend is not driven by changes in workers' application behavior: the shares of downward and cross-major applications remain relatively stable. Instead, the rise in mismatch reflects changes in employer selection, with mismatched applicants increasingly represented among positive replies.

To identify the causal effect of LLM-related technological change, the paper exploits the release of ChatGPT in late 2022 as a salient shock and estimates difference-in-differences and event-study specifications across occupations with different baseline LLM exposure. The results show that, after the shock, high-exposure occupations receive more applications but experience lower positive-reply rates, indicating intensified competition. More importantly, LLM exposure significantly reduces downward applications and vertical mismatch, while having no statistically meaningful effect on cross-major applications or horizontal mismatch.

Mechanism analyses point to employer-side job redesign as the central channel. Following the LLM shock, postings in highly exposed occupations list more tasks and skills and exhibit higher skill complexity, suggesting greater specialization and clearer requirement signals. These changes reduce information frictions and limit "luck-based" entry by underqualified applicants, thereby lowering vertical mismatch within exposed occupations. At the same time, the paper documents heterogeneity across job ladders and worker types, indicating that reduced mismatch in high-exposure occupations may coexist with rising pressure elsewhere in the labor market.

Overall, the paper makes three contributions. First, it refines a transparent, task-based measure of LLM exposure tailored to the Chinese context. Second, it leverages job–applicant match data to study mismatch at the point of market interaction rather than ex post outcomes. Third, it shows that generative AI can improve matching efficiency within exposed occupations through job specialization and clearer signaling, even as aggregate mismatch remains high. These findings highlight the importance of employer responses and institutional context in shaping how new AI technologies affect labor market efficiency.

人工智能技术进步与劳动力市场错配：来自中国线上招聘平台“岗位-求职者”匹配数据的证据

于航[a,b]、李泓孛[a,b]、张丹丹[a,b]、张润博[a,b]、李强[c]

(a.中国经济研究中心；b.北京大学国家发展研究院；c.北京网聘信息技术有限公司)

摘要：本文基于 2021 年 1 月至 2025 年 7 月间约 162 万条求职者和岗位匹配的线上招聘平台数据，考察了人工智能大语言模型（AI-LLM）技术对劳动力市场错配的影响。本文首先优化了职业层面 AI-LLM 技术暴露指数，并构建了纵向（基于学历）错配和横向错配（基于专业）测度指标。在此基础上本文采用双重差分与事件研究法识别 AI-LLM 技术发展对劳动力市场错配的影响。研究发现 2021 年后中国劳动力市场错配整体加剧，但在 ChatGPT 等技术冲击后，高 LLM 暴露职业的纵向错配相对减轻，招聘岗位的需求信号更精准、技能要求与学历门槛也随之提升。本文从“岗位－求职者”匹配视角揭示了人工智能对劳动力市场匹配效率的影响机制。

关键词：人工智能、劳动力市场错配、暴露指数

JEL 分类号：J24, J31, J62

一、引言

近年来，人工智能技术（AI, Artificial Intelligence）的快速发展与广泛普及，尤其是大语言模型（LLM, Large Language Model）的推广应用和迭代升级，突破了传统生产的边界，大幅度提高了生产效率，孕育出智能物联网等新兴产业领域。毋庸置疑的是，AI 技术进步在为产业发展注入强劲动力的同时，也在深刻影响着劳动力市场中用人单位的岗位形态、技能要求与需求结构，同时释放着新的信号对求职者的职业选择和教育投入带来影响，供需双方的匹配效率由此发生了调整，对劳动力市场结构性问题带来了新的冲击。

诸多实证研究表明，工业机器人、人工智能等技术对就业带来了显著的替代效应（Autor et al., 2003；Acemoglu and Autor, 2011；Goos and Manning, 2007；Brown et al., 2020；Bommasani et al., 2021）。以 ChatGPT 为代表的大语言模型作为 AI 时代下的新一轮技术冲击，其具备复杂语义理解能力和跨任务迁移能力，能够执行包括文本撰写、代码生成、知识索引等在内的高认知任务。AI 技术不

再局限于冲击可程序化、规则明确的中低技能岗位，已经开始深度介入专业性、创造性要求较高的职业活动。

需求端面临深刻变革的同时，供给端也发生着重要变化。随着我国教育制度、专业培养体系的不断丰富与完善，大学和高等职业学校不断扩招，高校新毕业生人数进一步扩大，已连续四年突破千万级别，且呈现上涨趋势，高质量的劳动力源源不断的流入就业市场。需求端的技术驱动型变革与供给端的规模扩张型增长相互交织，为中国劳动力市场带来了新的挑战与疑问：在这样的双重背景下，当前市场的就业质量究竟如何？求职者在岗位选择时，是真正找到了与自身能力、教育背景相契合的方向，还是陷入了“错配”的困境？回答这些问题对 AI 时代下的个人职业发展和社会资源的有效配置有着重要意义。

关于劳动力市场匹配度这一话题，学者多用“错配”（mismatch）这一表述。劳动力市场错配有不同的定义与研究角度，根据 OECD（2017）的分类，劳动力市场中的错配问题大致可以分为学历、专业、技能（qualification, skill, and field-of-study mismatch）三个主要的方面。当求职者匹配职业的学历要求、专业要求与技能要求与自身实际人力资本水平不一致，即认为是错配现象。

利用 2021 年 1 月至 2025 年 7 月的近 162 万条线上招聘平台的“岗位-求职者”匹配数据，本文从基于学历的纵向维度（vertical mismatch）和基于专业的横向维度（horizontal mismatch），对人工智能时代下劳动力市场的错配趋势进行探索。研究发现，在样本期内，中国劳动力市场的纵向、横向错配比例平均维持在 59.9% 和 45.1%的较高水平，且均存在显著的上升趋势。错配情况在不同职业中存在明显差异，且在求职者的年龄、学历等方面存有显著异质性。

本文进一步研究了受大语言模型人工智能技术影响不同的职业与劳动力市场错配的关联。在张丹丹等（2025）的“大语言模型人工智能技术暴露度”（AI-LLM 暴露指数）的核心思路的基础上，本文对任务提取与匹配环节细化、优化，将其拆分为四个连续的流程，使整个指数构建过程更具可追踪性和可复现性。应用计量分析的方法，本文探究了职业层面的 AI-LLM 暴露指数与市场错配情况的关联，并对机制进行探索。研究发现，随着大语言模型人工智能技术的应用，与低暴露度职业相比，高暴露度职业的向下投递与纵向错配比例明显降低，这源自于其更为精准的需求信号与不断提升的技能复杂度与学历门槛，从而更容易促成纵向适配的市场均衡。

本文的贡献主要体现在三个方面。第一，结合最新的自然语言处理技术与招聘广告抽样数据，本文细化、优化了张丹丹等（2025）的“大语言模型人工智能技术暴露度”的构建过程，重构了一套更加透明、严谨且适配的暴露指数。第二，本文创新性地利用“岗位-求职者”相匹配的招聘大数据，探索了 AI 时代下劳动力市场中的教育错配现象，构造了更为科学的衡量指标，并揭示了大语言模型人工智能技术与市场错配的关联，以及这一现象背后的形成机制。第三，本文为政策端制定针对性就业引导政策、教育端优化专业与学历培养体系，以及求职者调整职业适配策略提供了实证依据。

文章余下部分的安排如下：第二部分回顾相关文献。第三部分详细介绍本文采用的数据、暴露指数的重构以及纵向、横向错配的测度方法。第四部分展示 AI 时代下劳动力市场错配的宏观趋势与异质性分布。第五部分基于 AI-LLM 暴露指数的计算结果，采用计量分析的方法研究市场错配与职业暴露度的关联。第六部分对实证结果背后的机制进行分析。第七部分是总结与建议。

二、文献综述

本文的工作主要包括三部分：一是重构中国劳动力市场的大语言模型人工智能技术暴露度；二是梳理中国劳动力市场中的纵向、横向错配情况；三是探究大语言模型人工智能技术对劳动力市场错配情况的影响。本节分别就这三个方面进行相关文献的综述并讨论本文与已有文献的关系。

（一）大语言模型人工智能技术暴露度的测算

在人工智能技术深度融入经济社会的背景下，如何在保证时效性的同时精准、系统地测算其对产业结构、劳动力市场、岗位需求的实际影响，始终是学界与政策制定者面临的核心难题。目前研究大多通过暴露指数（Exposure Index）构建可量化的评估框架，将人工智能对特定对象（如岗位、行业、劳动群体）的“潜在影响程度”转化为直观数据，为精准衡量人工智能冲击提供了关键抓手。

梳理现有文献可见，人工智能技术暴露度的构建路径中，“基于工作任务”的方法占据主流地位。这一方法以 Autor et al.（2003）的“基于任务的工作模型”为理论基础，突破了传统“以职业为整体”的测算局限——首先将职业解构为一系列具体的、可执行的工作任务，在任务微观层面分析人工智能技术对人类劳动的替代可能性与替代程度，随后再依据统一的统计逻辑，将任务层面的测算结果向上整合，最终形成覆盖职业、地区等不同分析维度的人工智能技术暴露度指标。

Felten et al.（2021）、Webb（2020）、Eloundou et al.（2024）通过任务匹配与文本语义方法，结合专家、大语言模型评分的方式，构建出职业层面的人工智能暴露度指数，以此量化美国不同职业、行业及地区面临的人工智能技术替代风险。其研究发现，人工智能对劳动力市场的影响并非局限于低技能岗位，反而更倾向于渗透高技能、认知密集型职业（如程序员、律师等），且这一替代趋势在中高薪资区间表现得尤为突出。在此基础上，张丹丹等（2025）进一步将该分析框架适配中国本土情境，依托海量招聘大数据，对 2018 年 1 月至 2024 年 5 月中国劳动力市场的动态变化展开系统追踪，并基于任务视角（task-based approach）系统构建了人工智能大语言模型暴露指数（AI-LLM exposure index）。研究结果显示，随着以大语言模型为核心的新一轮人工智能技术加速落地，中国劳动力需求增速逐步放缓，与此同时，整体劳动力市场的人工智能大语言模型暴露指数呈现出持续下降的态势。综合来看，这些研究均以任务层面的精细化量化分析为核心，不仅为解析 AI 技术的劳动替代效应提供了扎实的经验支撑，更清晰揭示了新技术正在从岗位需求、技能匹配等维度，深刻重塑劳动力市场的内在结构。与张丹丹等（2025）相比，本文就指数构建过程进行了优化，将任务提取步骤从通过大语言模型直接从招聘广告文本中提取标准化任务拆解为具体任务提炼和利用 Sentence-BERT 框架与标准化任务匹配两个步骤，从而显著增加了指数过程的可解释性和可复现性，进一步增加了利用该指数进行分析得到的结论的严谨性和可靠性。

（二）劳动力市场错配

教育错配是指劳动者所受教育与工作岗位要求不匹配的现象，主要包括纵向错配（学历层次过高或过低，即过度教育或教育不足）和横向错配（所学专业与工作领域不对口）两种形式。大量研究表明，教育错配在各国劳动力市场中广泛存在，并带来显著的经济后果（Hartog，2000）。例如，Duncan and Hoffman（1981）最早采用计量方法衡量过度教育的工资效应，发现相对于受教育程度恰好匹配岗位的劳动者，过度教育者的工资有明显劣势；随后Verdugo and Verdugo（1989）的研究进一步证实了过度教育的“工资惩罚”效应。基于多国数据的荟萃分析表明，过度教育导致的工资损失平均约在10–20%之间（Hartog，2000），而教育不足劳动者反而因稀缺技能获得某种“工资溢价”（Verdugo and Verdugo，1989）。与纵向错配相比，横向错配受到较少关注，对工资的影响相对较小且结论不一：Somers et al.（2019）对相关文献的系统综述表明，横向错配在普遍意义上存在“工资惩

罚”效应，但仍有部分研究发现专业不对口并未显著降低工资水平。总体而言，横向错配的收入惩罚效应普遍弱于纵向错配（McGuinness，2006；Robst，2007）。

就测度方法而言，文献中对纵向错配的测量主要有三种方法：（1）工作分析法（job analysis）按照职业分类预先设定各职业所需的教育水平，将劳动者的受教育程度与该标准相比以判断是否错配，该方法最早在Eckaus（1964）中提出。（2）统计或实际匹配法（realized matches）根据实际数据计算特定职业中从业者的平均或众数教育水平，并将个人教育水平与之比较，如高于一个标准差则视为过度教育（Verdugo and Verdugo，1989），该方法在后续关于纵向教育错配的研究中被广泛应用。（3）自我评估法（self-assessment）直接询问劳动者所从事工作的所需学历或其自我感觉是否学非所用，从而识别错配情况（Verhaest and Omey，2006）。对于横向错配，测量方法也类似，可以通过主观调查或客观匹配的方式判定。主观调查的核心思路在于由受访者界定自身的专业领域是否与工作相关联（Bender and Heywood，2011； Bender and Roche，2013；Robst, 2007）。客观匹配则是通过标准化工具或专业框架建立“专业-岗位”的匹配基准，目的是减少主观感知造成的偏差（Béduwé and Giret，2011；Wolbers，2003）。需要注意的是，不同测度方法会产生不同的错配发生率估计。就本文而言，考虑到提高结论的严谨性和透明性，本文对横向错配和纵向错配的定义均采取客观匹配的思路，详细定义方法将在第三部分具体介绍。

在中国，高等教育大众化进程加剧了教育错配问题的凸显。自1999年高校扩招以来，大学毕业生数量迅猛增长，但相应的高技能岗位增长相对滞后，导致“高学历人才供过于求”的结构失衡（李晓光等，2023）。近期研究估计，中国劳动力市场的学历层次错配率约为24%，专业错配率约为34%（李晓光等，2023），总计有接近三分之一的新毕业生从事的工作要么低于其受教育水平要求，要么与所学专业不符。从动态趋势看，教育错配可能并非短期过渡现象，有证据表明不少劳动者在整个职业生涯中持续面临学历或专业错配（李晓光等，2023；Wolbers，2003）。在影响方面，大量国内外文献聚焦于教育错配的工资效应和职业发展后果。总体而言，与学历匹配者相比，学历过度或专业不对口的劳动者起薪和后续工资增长均受抑制（李骏，2016；刘云波，2019；Tsai，2010）。例如，刘云波（2019）利用中国综合社会调查数据发现，过度教育使劳动者工资显著降低，而横向不对口对工资的影响不明显。不仅如此，一些研究揭示教育错配可能带来“疤痕效应”，影响劳动者的长期职业机会：李晓光（2024）的实验研究发现，简历

中有过度教育经历的求职者收到的面试回复率显著偏低，表明学历层次错配会降低雇主对求职者能力的信心，造成持久的就业劣势。

教育错配的成因相当复杂，既有供给侧因素也有需求侧原因。供给方面，劳动力受教育结构迅速提升而岗位设置调整相对滞后，导致高校毕业生“高不成低不就”现象普遍（李晓光等，2023）。个人特征上，年轻人、职场新人往往因缺乏经验更容易出现就业初期的学历错配，而女性和移民群体的错配率也被观察到更高（Frank，1978；Green et al.，2007）。需求方面，一些用人单位可能存在对高学历求职者的偏见或担忧，例如认为“人才大材小用”会导致离职率上升，这在中国情境下也有所讨论。Kuhn and Shen（2013）的研究利用中国某大型招聘网站数据考察了用人单位是否会回避录用“学历过高”的求职者。结果显示，对于申请要求大专学历的岗位时，本科毕业生并未遭到显著歧视，但当大专学历求职者竞争要求中专或技校学历的岗位时，“学历过高”反而降低了其成功率。这表明学历纵向错配在一定情况下会对就业产生负面影响，也凸显了中国高校毕业生在就业市场中面临的结构性困难。

总的来看，既有文献充分揭示了教育错配现象的普遍性及其对个人薪资、就业机会的负面影响。然而，仍有若干方面值得进一步拓展。首先，大部分研究采用劳动力调查或毕业生调查数据，对宏观层面的错配比例和后果进行了分析，但缺乏对劳动力市场供需两端匹配过程的细致描绘。本文利用大规模在线招聘市场“岗位–求职者”投递匹配数据，能够从微观层面直接观察岗位要求与求职者教育背景之间的匹配情况，从而详细刻画当前中国劳动力市场教育错配的整体状况，弥补以往研究在供需匹配视角上的不足。其次，以往文献较少关注技术变革背景下教育错配的演进与影响。本文将这一要素纳入考察，通过匹配数据直接分析新兴技术冲击如何改变劳动力市场的匹配效率，在教育错配研究领域提供了新的视角。

（三）技术进步、人工智能技术与劳动力市场错配

技术进步对劳动力市场的影响一直是经济学关注的核心议题。经典研究表明，20 世纪末的信息技术革命带来了技能偏向型技术变革，提高了高技能劳动的相对需求，扩大了不同技能劳动者之间的收入差距（Acemoglu and Autor，2011）。Autor et al.（2003）提出的基于任务的技术变迁模型进一步解释了就业结构的变化：计算机和自动化主要替代了可程序化的常规性中等技能任务劳动，却难以取代高技能的抽象认知任务和低技能的非例行体力服务任务。这一理论与发达国家

近几十年的就业极化趋势相符合：中等技能制造业和文职岗位就业占比下降，而高技能、高收入职业和低技能服务业岗位的占比同时上升（Autor and Dorn，2013；Goos and Manning，2007）。随着自动化深化，中等收入行业的劳动力向两端分流，产生就业极化现象（Autor and Dorn，2013）。就业极化和技能需求转变还带来了显著的社会后果，包括中产阶级萎缩、劳动力市场不平等加剧等（Autor，2015）。就技术进步对中国劳动市场的影响而言，王永钦和董雯（2020）、李磊等（2021）、闫雪凌等（2022）、陈媛媛等（2022）、Giuntella et al.（2025）的研究发现，工业机器人技术的应用对劳动力需求产生了显著的替代效应，不仅减少了地区外来劳动力的流入，还压低了劳动者的工资性收入，这种负面冲击主要集中在低技能劳动者群体。同时，机器人的引入也推动了岗位结构的调整，促使劳动者由繁重劳动向非繁重劳动、由常规性岗位向非常规性岗位转移（王林辉等，2023）。

人工智能技术与以往机械自动化和计算机化主要替代体力劳动和简单脑力劳动不同，尤其是大语言模型（LLM）等技术，具备复杂的语义理解和跨任务学习能力，能够执行诸如文本写作、代码生成、信息分析等高认知度任务（Brynjolfsson and McAfee，2014）。这意味着人工智能技术的替代范围正从过去“可编程工作”拓展到“高度专业和创造性的不可编程工作”领域（Brynjolfsson and Mitchell，2017；张丹丹等，2025）。Autor（2015）指出，尽管历史上技术进步不断创造新岗位以抵消被替代的旧岗位，但人工智能的崛起使得传统上由高技能白领承担的任务也开始被自动化工具分担，人们对未来就业前景的忧虑有所加深，Eloundou et al.（2024）的实证研究结论支持了上述判断。Frey and Osborne（2017）采用职业任务可自动化概率测算的方法预言，大约47%的现有职业岗位有被自动化取代的高风险，引发了人工智能将导致大规模失业的讨论。总体而言，当前共识认为 AI 对就业的影响具有“双重效应”（Autor，2015；Acemoglu and Restrepo，2019）：一方面，人工智能在某些领域替代了人工劳动，导致岗位减少或技能需求下降；但另一方面，人工智能也创造了新的工作任务和岗位（例如数据标注师、算法维护工程师等），并通过提高生产率带来间接的就业拉动效应。长期看，人工智能对总就业量和就业结构的净影响取决于替代效应与创生效应的此消彼长（Acemoglu and Restrepo，2019）。

然而，到目前为止，关于人工智能技术如何影响教育错配的学术研究仍十分有限。已有的研究多集中讨论此前几轮技术变革，如谢尚等（2024）利用互联网的普及有助于降低求职信息不对称，从而减少学历层次错配的风险。现有关于人

工智能对劳动力市场影响文献主要从劳动力需求侧切入，讨论人工智能对就业数量和结构的影响，对供给侧人力资源配置的结构性问题关注不足。部分学者开始构建指标量化人工智能对职业的影响程度，并分析其经济后果。比如，Felten et al.（2021）基于人工智能对不同职业任务的胜任度构建了职业暴露指数，为衡量各行业、各地区受到人工智能冲击的程度提供了工具。在中国情境下，张丹丹等（2025）结合大语言模型技术发展，测算了我国各职业的大语言模型人工智能技术暴露度，并考察其对劳动力需求的影响。研究发现，暴露度较高的职业呈现出劳动力需求升级的趋势：这些职业的新招聘岗位更倾向于要求高技能、高学历人才，低技能岗位需求相对萎缩。人工智能进步正在推动劳动力需求结构朝着更高技能方向转型。但需求侧的变化只是问题的一个方面，供给侧劳动者能否及时提升技能、匹配岗位要求，同样决定了技术进步的整体就业影响。如果劳动者的教育培训跟不上技术要求提高的步伐，就会出现“技术变革速度快于人力资本调整速度”的落差，从而在劳动力市场上表现为结构性错配和人才浪费。

基于上述背景，本文从劳动力供给侧视角切入，研究以大语言模型为代表的人工智能技术进步对劳动力市场教育错配的影响及作用机制。将人工智能技术进步纳入错配研究框架，拓宽了技术对劳动力市场影响的分析维度。以往关于人工智能的讨论多集中在其对就业数量和技能结构的影响，鲜有关注 AI 对劳动力市场匹配效率和结构性失业问题的作用。本文填补了这一空白，实证上检验识别了大模型人工智能技术冲击对教育错配率的影响。另外，本文的结论丰富了对人工智能经济影响的认识。本文揭示了人工智能技术进步不仅会改变岗位需求结构，也会通过影响求职–招聘匹配过程来重塑劳动力市场的配置效率。这一发现为全面评估人工智能的社会经济影响提供了新视角。

三、研究数据与关键指标的测算

本节将介绍本文的研究数据与处理过程，并详细阐述对计算 AI-LLM 暴露指数的流程改进，以及纵向、横向错配的测算方法。本文的研究数据源自智联线上招聘平台。作为 1994 年便已成立的头部在线招聘平台，智联招聘在国内市场占据重要地位——其在线招聘市场份额超 30%，同时积累了 3.74 亿活跃个人用户与近 1,436 万企业用户，样本覆盖广度与深度使其对城镇劳动力市场具备了一定的代表性。

在线招聘广告具有实时性强的特点，能够及时追踪劳动力市场中需求端的变化，对于测算暴露指数有着天然优势。此外，智联招聘大数据还能够捕捉到求职

者的投递记录与入职意愿，有助于研究市场均衡下的匹配情况。需要注意的是，已有研究表明（Kuhn and Shen，2013；张丹丹等，2025），在线招聘广告通常更集中于城市地区、相对年轻且高学历人群，以及中高薪酬岗位，因此在将结果推广至整体劳动力市场时需谨慎解释。本文选用数据包括两部分。第一部分数据为按年抽样的招聘广告数据，用于计算 AI-LLM 暴露指数。第二部分数据为"岗位-求职者"匹配数据，我们基于此数据构建了教育错配的相关指标，"岗位-求职者"匹配数据也是后文研究分析的主要样本来源。

（一）招聘广告数据与"大语言模型人工智能技术"暴露指数的构建

我们使用来自智联招聘平台 2018 至 2020 年间的约 60 万条招聘广告随机样本，构造了中国劳动力市场职业层面的"大语言模型人工智能暴露指数"。指数构造基于本文的核心"求职者-匹配"样本覆盖起始（2021 年）之前，避免了指数的内生性问题。本文使用的暴露指数在张丹丹等（2025）的基础上进行了改进，结合 Hampole et al.（2025）的思路与招聘广告数据的具体特征，将任务提取这一工作细化为四个步骤，提高了构造过程的透明度和可追踪性[1]。

（二）"岗位-求职者"匹配数据介绍

本部分数据覆盖 2021 年 1 月 1 日至 2025 年 7 月 31 日，基于需求端的职位抽样，依据投递记录匹配求职者信息。我们首先从 2021 年至 2025 年，每年随机抽取 2 万个在智联平台上进行招聘的岗位（简称"岗位样本"），信息包括招聘广告的发布时间、岗位描述、职业、地域、行业等。然后，以"岗位样本"为基础，我们进一步提取了其中每个岗位发布当年收到的全部投递记录（包括求职者和投递时间），构成"投递样本"。所有出现在上述"投递样本"中的求职者构成"求职者样本"，对每一个求职者我们提取的信息包括求职者 ID、年龄、性别、学历、专业等基本特征，以及上一份工作经历。

每人次的投递还记录了求职结果，即是否达成"接近雇佣"。尽管招聘平台无法直接观察到企业的录用决策，但其会根据劳资双方在平台上的互动记录，判断企业与求职者之间是否互相表现出高度兴趣，平台内部术语为"正向回复"。"正向回复"是一个接近达成雇佣的中间步骤——在样本中，同一招聘广告的"正向回复"数与拟招人数的比值平均为 3.33，51.5％的招聘广告的"正向回复"数

[1] 详细的指标构造方法，以及与张丹丹等（2025）的对比，详见北京大学国家发展研究院 AI 与经济学实验室和智联招聘（2025）技术文本。我们在附录中亦做了简要总结。在本部分抽样数据中， 2018 年至 2020 年的数据样本与张丹丹等（2025）完全一致，保证了指数对比的可比性。

小于等于拟招人数。因此，在本文的分析中，我们把“正向回复”视作接近达成雇佣的状态，作为求职者与岗位匹配成功的代理变量。

我们对用于研究分析的样本做了进一步限制。首先，受抽样方式的限制，我们无法获得与招聘广告发布时间不同年份的投递记录，因而年底发布的“岗位样本”通常不能完整匹配所有投递记录。研究发现，近 90%的投递记录在招聘广告发布的两个月内进行，因此，我们在分析中只保留了每年 1-10 月发布的招聘广告（对于 2025 年的数据，保留 1-5 月发布的招聘广告），并匹配发布后两个月内的投递记录。其次，本文只保留招聘类型为全职的岗位及与之相对应的投递记录。

经上述处理，最终用于统计分析的有效样本量为：“岗位样本”共 97,447 个招聘广告；对应这些招聘广告的“投递样本”共 1,623,430 投递人次；这些投递来自于 1,439,854 个不同的求职者。其中，求职者学历在“大专及以上”的“投递样本”共 1,452,440 投递人次，来自于 1,279,223 个不同的求职者。表 1 展现了匹配数据中各年份的总投递人次以及正向回复的比例，其中，五年的平均正向回复率 19.44%；表 1 也对各年度中求职者的性别、年龄、学历三个特征的分布予以呈现。

表 1：“岗位-求职者”匹配数据的描述统计

	2021	2022	2023	2024	2025
Panel A：投递与回复情况					
总投递人次	148,182	302,425	393,225	357,796	421,802
正向回复率（%）	19.48	24.52	22.15	16.66	15.63
Panel B：求职者特征分布					
性别占比					
男性（%）	54.70	51.98	54.91	57.35	59.22
年龄占比					
16-24 岁（%）	21.39	29.29	25.30	22.95	19.19
25-34 岁（%）	50.15	46.14	44.12	42.48	42.07
35-44 岁（%）	22.05	18.95	23.20	25.61	27.87

45 岁及以上（%）	6.41	5.62	7.39	8.96	10.86
学历占比					
大专以下（%）	9.16	9.92	9.27	8.81	7.03
大专（%）	32.97	34.01	32.46	31.80	30.50
本科（%）	51.50	50.67	53.08	53.62	55.58
硕士/博士（%）	6.37	5.39	5.18	5.77	6.90

值得注意的是，纳入分析的 97,447 个招聘广告样本中，仅有 51.7%收到过投递，即“有投递样本”；未收到投递的招聘广告可能因为不受求职者青睐或通过线上平台以外的途径接收工作申请。经过对发现，有投递样本相比无投递样本，平均大语言模型暴露度更高（0.61 v.s. 0.55， p-value<0.001）、平均薪资更高（9627 v.s.9496， p-value=0.004）。有投递样本平均学历要求更高，更多集中在大专和本科，而无投递样本学历要求集中在无要求。从职业分布来看，有投递样本中有更多管理类职业、商业金融职业；而无投递样本有显著更多的生产类职业。由于后续分析有时限于有投递样本，我们会在分析前检验样本的选择性可能带来的偏误（附录三具体比较了有投递样本与无投递样本的特征）。

（三）基于“岗位-求职者”匹配数据构建教育错配指标

1. 职业、专业的标准化对应

为方便错配指标的构建，首先需要对招聘广告的职业与求职者的专业进行标准化。与国际上成熟的研究体系保持一致，我们将招聘广告的职业类别与求职者的专业分别对应到 SOC 职业分类标准与 CIP 学科专业标准。本小节进行具体说明。

SOC 职业分类标准（Standard Occupational Classification）是美国用于统一职业分类的全国性标准，由美国劳工统计局（BLS）、劳工部就业和培训管理局（ETA）等多部门联合制定，旨在为职业数据的收集、分析和发布提供统一框架，方便劳动力市场统计、就业服务、政策制定等场景的应用，首次发布于 1998 年，最新版本为 2018 年版。SOC 职业分类标准包含职组大类（Major Group，23 个，涵盖最广泛的职业领域，如“管理类”）、职组小类（Minor Group，98 个，大类下的细分领域，如“管理类”下的“首席执行官与高级管理人员”、广义职业（Broad

Occupation，459 个，职组小类下的分组，如“首席执行官与高级管理人员”下的“企业首席执行官”、具体职业（Detailed Occupation，867 个，具体职业名称，如“软件开发者”）。研究通过大语言模型辅助与专家筛选评估的方式，将“岗位样本”原始数据中近千种职业类别对应到 SOC 的具体职业。

CIP 学科专业划分标准（Classification of Instructional Programs）是美国用于高等教育学科专业分类的标准，由美国国家教育统计中心（NCES）制定，旨在统一高校专业设置的命名与分类，便于教育数据的收集、分析和比较。1980 年首次发布，最新版本为 2020 年版。CIP 采用六级层级结构，通过 6 位代码（部分扩展为 8 位）区分专业的细分程度，包括大类（Major，2 位，最广泛的学科领域，如“通信、新闻与相关程序”）、中类（Submajor，4 位，大类下的细分领域，如“新闻与大众传播”、具体专业（Detailed Program，6 位，具体专业名称，如“新闻学”）、细分方向（Program Specialization，8 位，部分专业的更细分支，如“新闻学（体育新闻方向）”）。研究通过 Sentence-BERT 语义相似度匹配与专家筛选评估的方式，我们将“求职者样本”中求职者自填的四万六千类专业对应到 CIP 的具体专业。在进行专业方面的研究时，研究只关注大专学历及以上的群体，这类群体的专业特点更为突出，且在“求职者样本”中占比超过 90%；此外，鉴于 CIP 主要是为高等教育的学科专业（涵盖副学士、学士、硕士、博士等层次）提供统一分类标准，对于初高中、中专中技等学历适配行较弱。

2. 纵向错配与横向错配的测算

本小节具体介绍基于学历的“纵向错配”与基于专业的“横向错配”的定义方法。为了更好的刻画线上求职过程，本文从投递视角出发，定义“向下投递”与“跨专业投递”。“向下投递”指“投递样本”中，求职者的学历高于申请岗位的学历要求的投递。本文将学历划分为五个层级：不限学历或初中及以下为 1 级；高中、中专、中技为 2 级；大专为 3 级；本科为 4 级；研究生为 5 级。根据学历层级的相对关系判断是否为“向下投递”。

“跨专业投递”指“投递样本”中，求职者所学专业与职位所要求的专业不一致的投递。其识别依赖于求职者的专业信息与职位所需专业之间的匹配关系，现有文献（如 Abel and Deitz, 2015; Manuel and Plesca, 2020; Manuel, 2024）大多将 BLS 与 NCES 协作构建的 CIP–SOC 对照表作为参考依据。本研究依据大语言模型辅助与 Sentence-BERT 语义相似度匹配，将智联招聘的职业分类与求职者专业分别对应到 SOC 职业标准与 CIP 专业标准中，将不在 CIP–SOC 对照表中的投递行为

视作跨专业投递。为减少模糊界定的影响，我们将 CIP–SOC 对照表中的 SOC 职业聚合到职组小类（Minor Group, 98 个），将 CIP 职业聚合到大类（Major，48 个）[2]。

由于大专及以上的申请者专业性较强、且该人群数量占求职者样本的超过 90%，因此在研究“跨专业投递”和“横向错配”问题时，我们将把样本分别局限在由大专及以上学历的申请者发出的投递和获得的正向回复中（下文简称“大专及以上子样本”），需要注意的是，对岗位要求学历不进行限制。

错配一般指实际入职匹配的情况，与投递行为仍有概念上的差距。由于招聘数据中无法追踪到实际匹配情况，本文用“正向回复”这一表示招聘双方意愿的指标进行间接反映。在有正向回复的“投递样本”子样本中，本文将“向下投递”视为“纵向错配”[3]，将“跨专业投递”视为“横向错配”。

在“投递样本”中，存在 2.0%的投递记录缺乏求职者学历信息，无法直接判断是否为“向下投递”；在“大专及以上求职者学历的投递子样本”中，存在 1.6%的投递记录缺乏原始专业信息，或是与 CIP 标准专业的语义相似度较低于阈值 0.5[4]，无法有效判断是否为“跨专业投递”。经分析，这两部分投递记录的其他特征分布与全样本特征分布存在显著差异，直接去除可能会对结果产生一定影响。本文采用机器学习算法，基于投递记录的其余信息，对关键信息确实的投递样本进行“向下投递”与“跨专业投递”的预测，详细信息参见附录六。

四、劳动力市场错配的趋势分析

（一）错配的整体趋势

应用“岗位-求职者”匹配数据，采用本文第三部分的测算方法，中国投递行为和劳动力错配的趋势如图 1 所示。

[2] 聚合层级会影响横向错配的测算，在附录四中对不同聚合层级下的平均横向错配比例予以呈现。
[3] 理论上，“向上投递”也属于“纵向错配”，但由于正向回复样本中几乎不存在求职者学历低于岗位要求的情况，因此本文不单独对“向上投递”进行考虑。
[4] 关于这一阈值的选择问题，参见附录五。

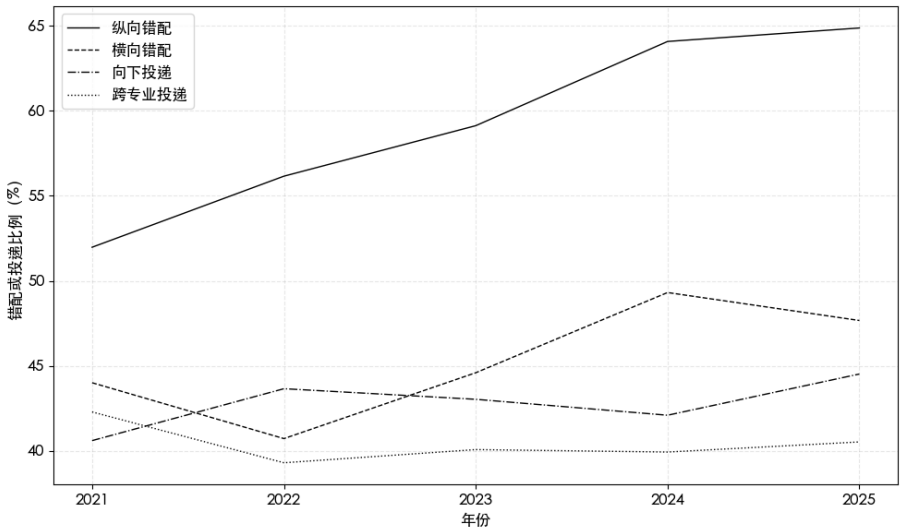

图 1：基于“岗位-求职者”匹配数据的投递行为和劳动力市场错配时间趋势

图 1 描述了劳动力市场中投递和错配趋势。2021 年至 2025 年间，40-45%的投递为高学历申请者向低学历要求的岗位进行的“向下投递”；约 40%来自大专及以上申请者的投递为“跨专业投递”。从劳动供给端来看，申请者的这两类投递行为在样本期间没有明显的变化趋势。然而，在样本期间，如果以“正向回复”作为供需匹配的代理指标，全市场的“纵向错配”比例从 2021 年的 52.0%逐年增长到 2025 年的 64.9%；“横向错配”比例也经历了从 40.7%的最低值增长到 49.3%的最高值。两种错配比例均明显呈上升趋势。

需要指出的是，本文所估计的纵向与横向错配比例在数值上高于既有基于劳动力调查数据的研究结果。既有文献多基于已就业劳动者样本，衡量的是就业存量中的学历或专业错配，相关研究在中国和国际样本中通常得到 20%–40%的错配率区间（Duncan and Hoffman，1981；Verdugo and Verdugo，1989；李晓光等，2023）。相比之下，本文使用的是招聘平台“岗位—求职者”投递与正向回复数据，刻画的是招聘筛选阶段的匹配结果，属于典型的流量型错配指标，其数值水平不宜与存量就业错配直接对比。相比之下本文的错配指标的优势在于能够及时地反应劳动力市场错配情况，同时在指标体系内部时间维度上可比。

“纵向错配”比例显著高于“向下投递”，相似的，“横向错配”比例也高于“跨专业投递”；说明用人单位总体更青睐于向下投递或跨专业投递的申请者，且这种偏好近些年越来越明显。其中，对向下投递的偏好尤为突出，蕴含着求职市场中日益凸显的“高学历优势”——高学历求职者的知识储备、学习能力等核心竞争力，往往更易获得用人单位的认可，成为筛选环节中的关键加分项。然而，这可能导

致原本恰好符合岗位学历要求的投递者被排除在外，最终推动了纵向错配现象的增多。

纵向错配和横向错配反映了下劳动力市场配置中的结构性问题[5]。不断增长的纵向错配表明，部分高学历群体面临“学历过剩”的困境，难以充分发挥其学历优势，可能造成人力资源的浪费，也可能加剧这部分群体的就业压力与职业满意度偏低的情况。不断增长的横向错配表明，教育专业设置与市场行业需求之间的衔接不够紧密，产业结构调整与人才培养体系之间存在一定的滞后性，难以快速响应市场对特定专业人才的需求变化。我们将在下文中探讨这一市场配置问题与当下人工智能技术革命之间的关系。

（二）错配的异质性

本文探究了纵向、横向错配在不同职业中的分布情况。图 2 分别呈现了给定岗位学历要求，纵向错配比例与横向错配比例最高、最低各五个职业[6]。结果显示，纵向、横向错配在不同职业中呈现出鲜明的异质性。

专业服务业岗位，如法律、教育、科学相关岗位的纵向错配率最高；相关大专岗位的工作机会容易受到本科申请者的挤占；而相关本科岗位的工作机会，也同样受到更高学历申请者的青睐。但这类职业专业性强这一特点，使其横向错配比例更低，无论是大专岗位还是本科岗位，它们较少受到其他专业申请者的冲击。

大专岗位中的蓝领工作不能吸引本科申请者的投递，纵向错配较少；但由于其专业性低，这类职业在大专申请者内部的横向错配也是最严重。同样，本科岗位中与生产制造相关的职业也是横向错配最严重的职业。

本科岗位中的管理类、文员类职业缺乏对高学历申请者的吸引力，也保持了较低的纵向错配，基本匹配本科申请者。

[5] 值得注意的是，线上招聘数据不足以覆盖整个劳动力市场的情况。就智联招聘平台而言，求职者以青壮年、中高学历居多，这部分群体往往更容易发生错配，所以图 3 中测算的比例可能是对中国总体劳动力市场情况的高估。

[6] 职业聚合依据为 SOC 的 Minor Group，出于严谨性考虑，样本量低于 100 的职业不参与比较。

面板 A：纵向错配

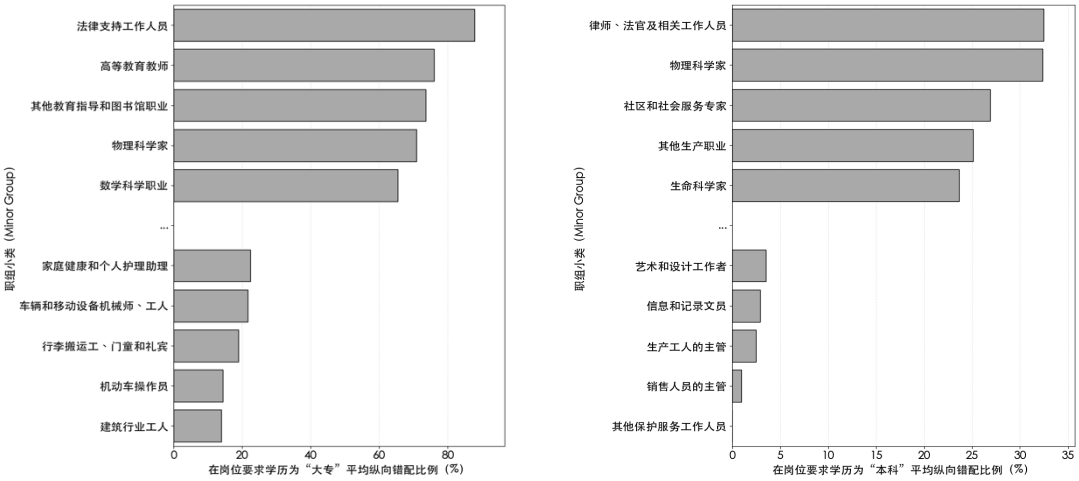

面板 B：横向错配

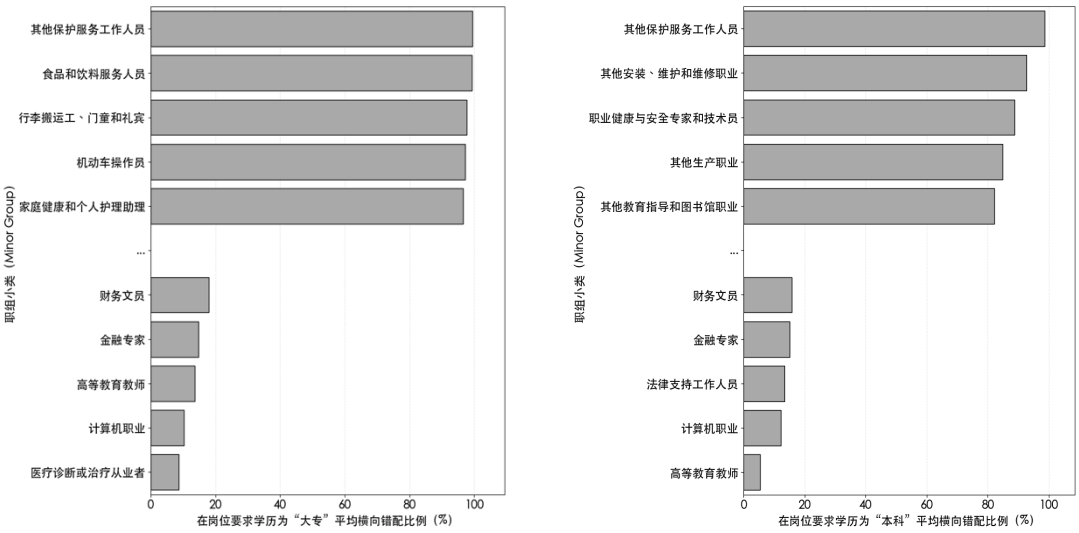

图 2：平均错配比例最高和最低的各五个职组小类，给定岗位学历要求

本文进一步探究了纵向、横向错配在求职者年龄、学历方面的异质性。本文将求职者年龄汇总为五个大类：16-24 岁、25-29 岁、30-34 岁、35-44 岁、45 岁及以上。学历方面，在纵向错配中对中专/中技/高中、大专、本科、硕士/博士四个学历层级进行呈现，在横向错配中对大专、本科、硕士/博士三个学历层级进行呈现。图 3 呈现了不同求职者群体平均纵向错配比例和平均横向错配比例的分布情况，颜色的深浅反映错配比例的严重程度。

面板 A：纵向错配

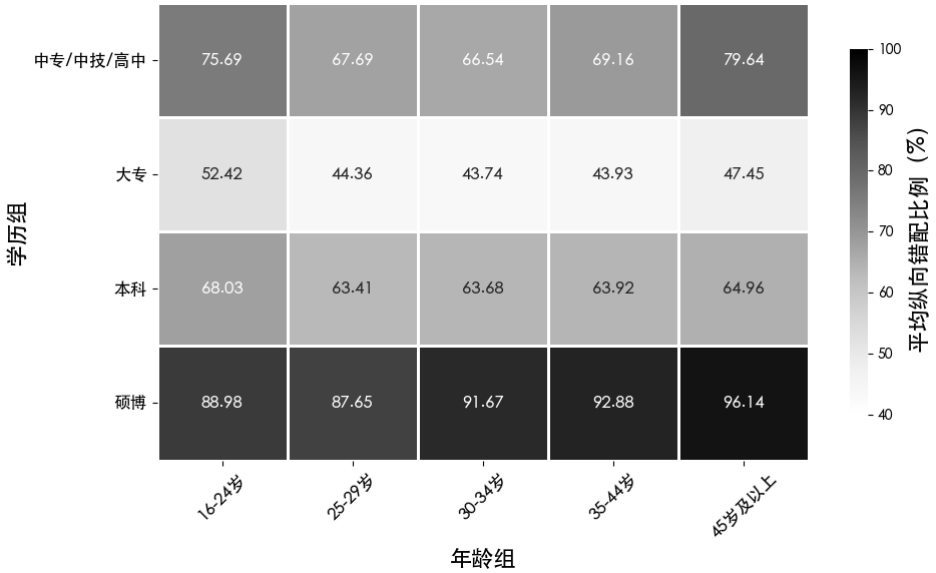

面板 B：横向错配

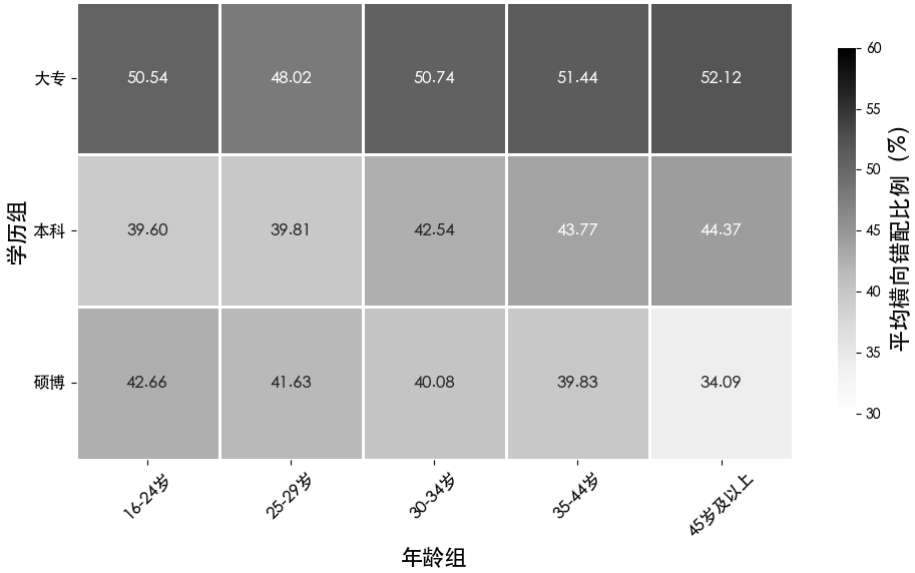

图 3：分年龄、学历求职者群体平均错配比例分布情况

从图 3A 的纵向错配分布来看，学历维度呈现出“中间低、两头高”的非线性特征：大专学历的申请者总体纵向错配比例最低，大部分匹配向了大专专业的岗位；而高、低学历的申请者则经历了更严重的错配：高中学历求职者大量涌向无学历要求的岗位；本科及以上学历申请者则广泛涌入大专岗位。从求职者年龄来看，16-24 岁青年群体与 45 岁及以上中年群体的平均错配比例显著高于其他年龄段，体现出低龄和高龄求职者在劳动力市场上的不利地位。

图 3B 展示的横向错配分布呈现出不同特征。与纵向错配相反，大专学历的求职者的横向错配比例最高，这可能与大专学历群体的专业技能相对基础、职业选择灵活性较高有关。年龄维度方面，大专学历求职者的横向错配比例基本保持稳定，本科学历求职者的错配比例随年龄增长略有上升，而硕士博士学历求职者的错配比例随年龄增长呈现显著下降的趋势。

五、AI-LLM 职业暴露度对劳动力市场错配的影响

本节具体研究了职业暴露度对求职者投递行为与市场错配的影响。本节首先通过散点图，在职业层面探究了职业的基期暴露度与 ChatGPT 发布前后错配比例变动的关联；进而采用双重差分法、事件研究法，分别在招聘广告层面、投递层面进行实证分析；本节还分招聘岗位的异质性对暴露指数对市场错配的动态影响进行分析。

（一）职业错配比例的变动与职业暴露度的关系

图 4 呈现了职业错配比例的变动与职业暴露度的关系。具体而言，图中每个点代表 SOC 广义职业，横坐标为该职业的暴露指数，纵坐标为该职业在 ChatGPT 发布后的平均错配比例与 ChatGPT 发布前的平均错配比例的差值。为了稳健性，图中删除了包含样本较少的职业点。左图呈现了纵向错配的变动情况与职业暴露度的关系，右图呈现了横向错配的变动情况与职业暴露度的关系。可以初步发现，高暴露度职业的平均错配比例的增长幅度显著低于低暴露度职业，甚至在较高暴露度的职业中有所下降；而在横向错配的比例变动中，高低暴露度职业并没有呈现出明显的异质性。下一小节将通过更严谨的实证方法提供证据。

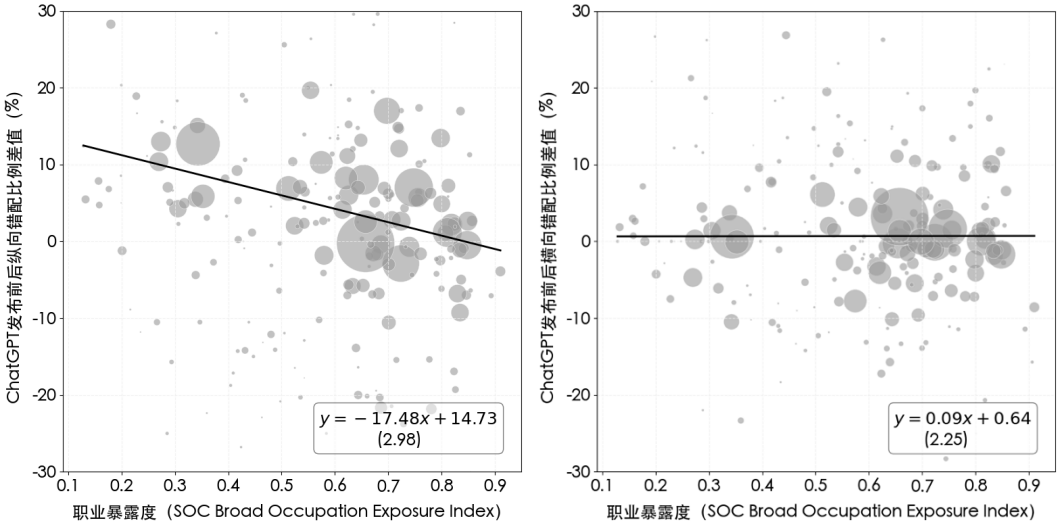

图 4：职业错配比例的变动与职业暴露度的散点图

注：左图代表纵向错配的情况，右图代表横向错配的情况。图中每一个点代表职业（SOC 广义职业，6 位编码），点的大小代表在 ChatGPT 发布前的职业份额占比大小，横坐标为该职业的暴露度，纵坐标为该职业在 ChatGPT 发布后（2022 年 12 月-2025 年 7 月）与 ChatGPT 发布前（2021 年 1 月至 2022 年 11 月）的平均错配比例的差值。每个图的右下角标注了采用加权最小二乘估计的拟合曲线，括号中为对应系数的标准误。

（二）双重差分实证方法

本文以招聘广告为主要研究对象，采用双重差分法，识别新一轮人工智能技术冲击对中国劳动力市场错配的因果影响。我们以 ChatGPT 的发布作为技术冲击到来的标志，识别其对潜在“大语言模型暴露度”不同的职业的不同影响。具体而言，我们使用以下回归方程：

1. 双重差分（Differences-in-Differences, DiD）回归

$$Y_{ijct} = \alpha + \beta ExpOccu_j \times Post_t + \gamma X_i + \mu_{ct} + \lambda_j + \epsilon_{ijct} \quad (1)$$

其中，i表示招聘广告，j表示招聘广告所在的 SOC 广义职业，c表示城市，t表示时间，具体到月份。Y_{ijct}为本文关注的被解释变量，本文使用了两类特征展开分析。

第一类特征聚焦市场的投递与正向回复（接近雇佣）情况：（1）招聘广告是否有求职者投递（2）招聘广告收到的投递量（3）招聘广告的正向回复率。

第二类特征聚焦市场的错配情况：（1）招聘广告收到的向下投递比例（2）招聘广告的纵向错配比例（3）招聘广告收到的跨专业投递比例。（4）招聘广告横向错配比例。

$ExpOccu_j$表示该招聘广告所在的职业j的暴露指数，为方便解释回归结果，回归中使用的暴露指数进行了 Z-Score 标准化处理。本文选取 ChatGPT 的发布作为主要事件冲击，$Post_t$是关于冲击时期的指示变量，在 2022 年 12 月及之后取值为 1，此前取值为 0；X_i表示招聘广告层面的一系列控制变量，包括该岗位的拟招聘数量、要求学历、月薪、岗位所在企业所有制类型、岗位所在企业规模等。μ_{ct}表示"时间-城市"层面的固定效应，它可以控制由于招聘平台的经营策略引起的地区间劳动力市场趋势不一致的情况；λ_j表示职业层面的固定效应。ϵ_{ijct}表示误差项。研究将标准误聚类到 SOC 广义职业层面，与核心解释变量的层面保持一致。

2. 事件研究法（Event Study）

$$Y_{ijct} = \sum_{\tau \neq -1} \beta_\tau I(t=\tau) \times ExpOccu_j + \gamma X_i + \mu_{ct} + \lambda_j + \epsilon_{ijct} \quad (2)$$

为进一步研究 ChatGPT 发布前后，不同暴露度的职业的错配情况的动态变化，本文采用事件研究法进行分析。为保证结果的稳健性，本部分将时间加总在季度层面，将 2022 年第 4 季度作为事件冲击的第 0 期。$I(t=\tau)$为时期的指示函数，当且仅当第τ期时取值为 1，其余情况取值为 0。其余变量与模型（1）保持一致。

（三）主要实证结果

表 2 基于双重差分法，呈现了大语言模型人工智能技术应用对市场投递与正向回复（接近雇佣）情况的影响。第（1）列展示了技术冲击并不显著影响招聘投递的外扩边际（extensive margin），即招聘广告收到投递的概率。第（2）列则显示技术冲击使高暴露度职业获得了更多投递，这一增加主要来自于集约边际（intensive margin）：与冲击前相比，职业暴露度每增加一个标准差，在有投递岗位中的投递数量平均增加 11.30 人次。投递人次的增加意味着竞争更加激烈，如第（3）列所示，高暴露度职业在技术冲击后的正向回复率显著下降。

表 3 是主要结果，呈现了技术冲击对市场错配情况的影响。第（1）列的结果显示，在技术冲击之后，更高暴露度的职业吸引了更少比例的向下投递，职业暴露度每增加一个标准差，向下投递比例将减少 2.6 个百分点。第（2）列使用了

所有形成了“近似雇佣”（正向回复）的岗位样本，被解释变量是岗位中所有形成了正向回复的匹配中纵向错配的比例。回归显示，技术冲击使得高暴露度职业的纵向错配比例同样下降。这意味着，与低暴露度职业相比，高暴露度岗位所吸引的向下投递与最终形成的纵向错配比例在冲击后明显降低，本文的机制部分将具体对这一现象展开分析。表 3 的第（3）（4）列相应地分析了跨专业投递与横向错配，没有发现技术冲击的显著影响。

图 5 对事件研究法中交互项系数β_τ的趋势变化进行呈现。其（1）-（4）部分图分别对应表 3 的第（1）-（4）列回归的事件研究版本。图 5 进一步确认了上述发现。技术冲击到来之前，暴露度不同的岗位在向下投递和纵向错配方面没有显著差异（系数接近 0）和变化趋势；2022 年 4 季度之后，交互项系数呈现出明显的降低，且在 2024 年底至 2025 年初尤为突出。

表 2：大语言模型人工智能技术应用对市场投递与回复情况的影响

	(1)	(2)	(3)
样本	全部岗位	有投递岗位	
结果变量	有投递	投递人次	正向回复率
ChatGPT 发布后	0.015	11.30***	-0.0300***
职业暴露指数	(0.0103)	(2.069)	(0.00613)
岗位控制变量	Yes	Yes	Yes
年月-城市固定效应	Yes	Yes	Yes
职业固定效应	Yes	Yes	Yes
观测数	91,897	46,462	46,462
调整后 R^2	0.482	0.157	0.334
被解释变量均值	0.517	33.274	0.343

注：“岗位控制变量”包括某岗位的拟招聘数量、要求学历、月薪、岗位所在企业所有制类型、岗位所在企业规模，第（3）列还控制了该岗位的投递人次。括号中为标准误（标准误聚类到职业层面，SOC 广义职业，6 位编码），***代表在 1%的水平上统计显著，**代表在 5%的水平上统计显著，*代表在 10%的水平上统计显著。

表 3：大语言模型人工智能技术应用对市场错配情况的影响

	(1)	(2)	(3)	(4)
岗位样本	有投递	有正向回复	有投递#	有正向回复#
结果变量	向下投递比例	纵向错配比例	跨专业投递比例	横向错配比例
ChatGPT 发布后	-0.0263***	-0.0230***	-0.00214	-0.000123
职业暴露指数	(0.00589)	(0.00572)	(0.00344)	(0.00487)
岗位控制变量	Yes	Yes	Yes	Yes
年月-城市固定效应	Yes	Yes	Yes	Yes
职业固定效应	Yes	Yes	Yes	Yes
观测值	46,462	31,096	42,262	26,999
调整后 R^2	0.721	0.63	0.603	0.524
被解释变量均值	0.545	0.592	0.496	0.505

注：#第（3）（4）列仅包含岗位要求为“大专”及以上的样本。“岗位控制变量”包括拟招聘数量、要求学历、月薪、岗位所在企业所有制类型、岗位所在企业规模、投递人次。括号中为标准误（标准误聚类到职业层面，SOC 广义职业，6 位编码），***代表在 1%的水平上统计显著，**代表在 5%的水平上统计显著，*代表在 10%的水平上统计显著。

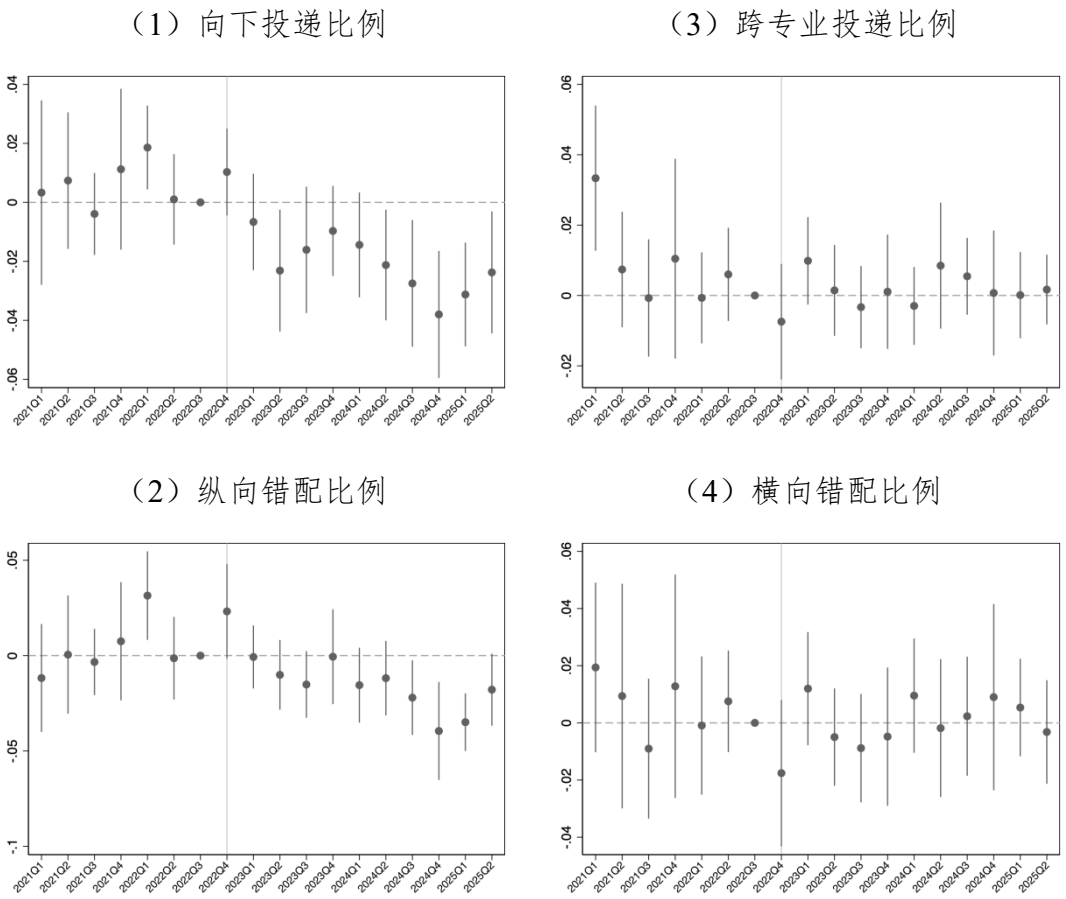

图 5：大语言模型人工智能技术冲击对市场错配情况的动态影响

注：图中呈现了事件研究法中交互项的系数。回归包含职业和年-季度的固定效应，同时控制了岗位要求学历、薪资水平等招聘广告层面的特征。标准误在职业层面聚类，置信区间为 95% 水平。

六、技术冲击下的错配机制与异质性分析

人工智能技术的快速发展，给企业带来了显著的任务重组与技能替代压力。对于高度暴露的职业而言，技术冲击不仅改变可自动化的任务边界，也改变岗位内部的技能结构，从而影响企业的岗位发布方式和求职者的投递行为。本章旨在探讨总体样本中错配持续上升而高暴露职业的纵向错配显著下降的现象，并揭示支撑这一变化的微观机制。

我们提出的核心机制假设是，技术冲击促使高暴露岗位在任务与技能维度上发生系统性调整，使岗位要求更专业化、技能组合更复杂，从而提高岗位信号的清晰度。当岗位要求变得更清晰、更专业时，求职者面对的信息不对称程度降低，

高学历但缺乏匹配技能的群体不再存在“运气式进入”的机会。因此，高暴露岗位的错配下降是由岗位专业化导致的有效匹配提高。

我们还发现劳动力市场的不同技能层级会呈现异质性的反应。高技能岗位（如本科要求、高薪岗位）因任务专业化程度提高而门槛上升；中技能轨道（如大专要求岗位）更容易被高学历求职者挤占；低技能轨道（低薪、低学历要求岗位）因未来学历回报不足而吸引力下降。此外，不同类型的求职者根据自身技能可迁移性和专业背景也会出现异质反应。

（一）需求端：高暴露岗位的任务与技能专业化

技术冲击首先作用于企业端的生产组织方式和岗位需求结构。当生成式 AI 广泛渗透后，高暴露职业的任务边界与技能需求会随之调整，使岗位内容呈现出更高的复杂度和专业化。本节利用岗位的任务数、技能数、技能复杂度和专业性等指标，对这一调整过程进行实证检验，作为前述“岗位信号更加清晰、错配由此下降”机制的直接证据。

我们从招聘广告的特征出发，从“岗位-求职者”匹配数据中的近十万个“岗位样本”中提取工作任务并对应到 O*NET 中的 Task。此外，本文借助大语言模型提取每个工作岗位所需的技能（具体提示词见附录七），并通过语义匹配将提取出的工作技能对应到 Lightcast 的分类体系。为更深入的从技能内容角度理解纵向错配的本质，本文对技能的复杂度与专业性进行量化。参考 Tacchella et al.（2012）、Aufiero et al.（2024）的做法，应用 EFC 算法（Economic Fitness and Complexity algorithm）计算工作适应性（job fitness）技能复杂度（skill complexity）。

表 4：企业发布招聘广告的主动调整

	(1)	(2)	(3)
被解释变量	工作任务数量	技能数量	最高技能复杂度排名
ChatGPT 发布后×	0.0710**	0.0812*	-2.013**
职业暴露指数	(0.0344)	(0.0468)	(1.016)
年月-城市固定效应	Yes	Yes	Yes
职业固定效应	Yes	Yes	Yes
观测值	46,462	45,390	45,053
调整后 R^2	0.256	0.506	0.346
被解释变量均值	3.699	9.532	271.862

注：回归中控制了该岗位的拟招聘数量、要求学历、月薪、岗位所在企业所有制类型、岗位所在企业规模、投递人次等变量，同时分别控制了年月和城市层面的固定效应。括号中为标准误（标准误聚类到职业层面，SOC 广义职业，6 位编码），***代表在 1%的水平上统计显著，**代表在 5%的水平上统计显著，*代表在 10%的水平上统计显著。

表 4 报告的结果显示，高暴露职业在技术冲击后经历了系统性的岗位内容重构。首先，在任务维度上，高暴露岗位的任务数量显著增加，表明岗位要求的工作内容更加丰富，涉及的任务组合更具多样性。其次，在技能维度上，这些岗位的技能需求数量也明显上升，反映出岗位需要更广泛或更综合的技能组合，求职者需要具备更全面的技能储备才能满足企业要求。

技能属性的结构性指标出现显著变化。技术冲击后，高暴露职业的技能复杂度（complexity）显著提高，意味着岗位要求的技能在不同维度上更具互补性，企业对能够综合处理多类任务的能力更加依赖。同时，技能专业性（specialization）显著上升，说明岗位要求的技能不再是通用型的，而是更加偏向特定领域或特定任务模块。这一变化与任务重构一致，显示企业将更多特定类型的任务内生地嵌入到岗位中，使岗位“画像”更加清晰、可辨识。

从劳动力市场机制角度看，这些岗位内容的变化意味着岗位的技能信号更明确、筛选标准更高。在技术冲击之前，不适配的求职者仍可能通过模糊的岗位描述或较高的信息不完全性，进入高暴露职业的申请序列；而在岗位任务和技能要

求变得清晰且高度专业化之后，这类求职者将减少对这些岗位的投递。这一变化直接导致高暴露职业的向下投递和纵向错配的显著下降。

（二）岗位层级的异质性

企业端岗位内容的专业化不仅改变了高暴露职业内部的技能需求，也系统性地影响了劳动力市场不同层级岗位的可进入性和吸引力。以下通过岗位学历要求和薪酬水平两个维度，检验技术冲击如何在不同层级的职业上引发的影响，并展示第三章中向下投递与纵向错配在不同岗位层级呈现的差异化变化。

技术冲击带来的任务和技能重构意味着：高技能岗位（如本科及以上要求、高薪岗位）的入职门槛会随专业化程度上升而抬高；中技能岗位（如大专要求岗位）在门槛上移与职业间竞争加剧的共同作用下，成为高学历求职者向下投递的主要承接层；而低技能岗位（如大专以下、低薪岗位）因未来技能回报有限、岗位吸引力下降，反而出现高学历求职者“主动撤离”的现象。

表 4 按岗位学历要求划分的结果为这一机制提供了直接支持。首先，本科岗位的向下投递与纵向错配在技术冲击后整体保持稳定。这一现象与前述“岗位专业化、技能信号更清晰”的机制一致：本科岗位本身位于职业梯度高端，其核心竞争者主要是具备相关技能与学历的求职者，岗位的专业化提升进一步强化了这一群体的优势，使错配在冲击后并未出现显著变化。其次，大专岗位呈现出明显的错配上升，尤其是向下投递增加更为突出。由于本科岗位的准入标准上移，高学历求职者难以在高技能轨道上找到预期位置，因而向大专岗位涌入，形成“中段梯度挤占”。这一现象是求职者面对新技术环境的典型表现。最后，大专以下岗位的错配显著下降。高学历求职者在技术冲击后对低技能岗位的兴趣降低。未来回报结构的变化使得高学历求职者不再愿意“向下迁移”。

薪酬维度的异质性（表 5）进一步佐证了这一机制。低薪岗位在技术冲击后呈现出向下投递和纵向错配的明显下降，这与大专以下岗位观察到的模式一致：低薪岗位与低技能岗位高度重叠，在技能专业化背景下对高学历求职者的吸引力显著减弱。相比之下，高薪岗位的错配变化较小甚至略有增加，主要因为高薪岗位更可能对应高技能轨道，其岗位内容的专业化提升强化了本就具备比较优势的求职者群体的竞争，而对不具备技能优势的求职者形成更强的挑战性。

综合上述证据，岗位学历要求和工资水平两个维度共同指向同一条经济机制：AI 技术冲击通过改变岗位内部技能要求，重塑了劳动力市场的职业需求结构，

使高技能门槛上移、中技能被挤占、低技能吸引力下降，从而导致不同岗位层级上的错配反应呈现系统性差异。

表 5：分岗位学历要求结果

	(1)	(2)	(3)	(4)	(5)	(6)
样本	本科岗位		大专岗位		大专以下岗位	
结果变量	向下投递	纵向错配	向下投递	纵向错配	向下投递	纵向错配
ChatGPT 发布后	0.00595	-0.00990	0.0239***	0.0242*	-0.0332***	-0.0358***
职业暴露指数	(0.00773)	(0.0162)	(0.00919)	(0.0131)	(0.00630)	(0.00557)
岗位控制变量	Yes	Yes	Yes	Yes	Yes	Yes
年月-城市固定效应	Yes	Yes	Yes	Yes	Yes	Yes
职业固定效应	Yes	Yes	Yes	Yes	Yes	Yes
观测值	9,197	4,844	14,352	9,040	18,923	14,300
R 方	0.337	0.309	0.306	0.311	0.243	0.238
被解释变量均值	0.111	0.114	0.452	0.467	0.860	0.866

注："岗位控制变量"包括拟招聘数量、要求学历、月薪、岗位所在企业所有制类型、岗位所在企业规模、投递人次。括号中为标准误（标准误聚类到职业层面，SOC 广义职业，6 位编码），***代表在 1%的水平上统计显著，**代表在 5%的水平上统计显著，*代表在 10%的水平上统计显著。

表 6：分薪酬水平的结果

	(1)	(2)	(3)	(4)
样本	高薪岗位		低薪岗位	
结果变量	向下投递	纵向错配	向下投递	纵向错配
ChatGPT 发布后	-0.0124*	-0.00549	-0.0230***	-0.0231***
职业暴露指数	(0.00714)	(0.0101)	(0.00623)	(0.00666)
岗位控制变量	Yes	Yes	Yes	Yes
年月-城市固定效应	Yes	Yes	Yes	Yes
职业固定效应	Yes	Yes	Yes	Yes
观测值	14,673	8,836	29,913	20,804
R 方	0.757	0.676	0.708	0.627
被解释变量均值	0.453	0.514	0.590	0.624

注："岗位控制变量"包括拟招聘数量、要求学历、月薪、岗位所在企业所有制类型、岗位所在企业规模、投递人次。括号中为标准误（标准误聚类到职业层面，SOC 广义职业，6 位编码），***代表在 1%的水平上统计显著，**代表在 5%的水平上统计显著，*代表在 10%的水平上统计显著。

（三）求职者的行为：技能比较优势和可迁移性

本节从求职者专业背景与工作经历两个维度出发，检验不同类型人力资本在新技术冲击中的相对表现，并展示上述机制如何在个体层面发挥作用。本部分我们沿用双重差分模型的方法，在"投递"层面进行回归分析，以求更精细地描述求职者行为。具体来说，我们使用了以下回归方程：

$$Y_{pijct} = \alpha + \beta ExpCurOccu_j \times Post_t + \gamma X_i + \theta Z_p + \lambda_j + \mu_{ct} + \epsilon_{pijct} \quad (3)$$

相对于回归方程（1），方程（3）以每个岗位-求职者投递为分析单元。下角标p代表求职者，其他字母含义保持与（1）相同，Z_p为求职者层面的控制变量。我们关心的被解释变量Y_{pijct}为该投递是否为向下投递；如果使用所有正向回复的投递样本，被解释变量则可解读为是否形成了纵向错配。

表 7：分求职者专业投递情况

	(1)	(2)	(3)	(4)
样本	STEM 专业求职者投递		其他专业求职者投递	
结果变量	向下投递	纵向错配	向下投递	纵向错配
ChatGPT 发布后	0.000576	-0.00363	0.00865**	0.0139***
职业暴露度	(0.00315)	(0.00380)	(0.00343)	(0.00353)
岗位控制变量	Yes	Yes	Yes	Yes
年月-城市固定效应	Yes	Yes	Yes	Yes
职业固定效应	Yes	Yes	Yes	Yes
观测值	459,380	78,756	967,768	167,777
R 方	0.779	0.792	0.784	0.768
被解释变量均值	0.392	0.541	0.430	0.599

表 7 汇报了分求职者专业而进行的等式（3）的回归结果。从专业背景来看，专业与岗位技能结构的一致性成为求职者在技术冲击后进入高暴露职业的关键条件。实证结果显示，STEM 背景的求职者在高暴露职业中并未出现显著的错配上升，有些群体甚至表现出更低的纵向错配。在岗位专业化增强的背景下，这类求职者具备更强的技术理解力、问题解决能力与任务迁移能力，能够适应岗位技能复杂度的提升，从而保留在职业梯度的高端轨道。因此，技术冲击不仅没有挤出这类求职者，反而强化了他们的比较优势。

与此形成对比的是，非 STEM 专业背景的求职者在高暴露职业中更容易受到岗位专业化提升的影响，其向下投递和纵向错配均出现显著上升。这一结果与前述“岗位信号更清晰”的机制一致：在技能要求提高后，非 STEM 求职者难以在高技能岗位上具备足够竞争力，从而被迫向下搜索新的就业机会。这一过程不仅导致高暴露职业内部的错配下降，也造成中段职业梯度（如大专要求岗位）的挤占，以及总体错配水平的上升。

表 8：分工作经历的投递情况

	(1)	(2)	(3)	(4)	(5)	(6)
样本	有高暴露度工作经历		有低暴露度工作经历		无工作经历	
结果变量	向下投递	纵向错配	向下投递	纵向错配	向下投递	纵向错配
ChatGPT 发布后	0.00775**	0.00996***	0.00263	0.00541	-0.000607	0.00525
职业暴露指数	(0.00383)	(0.00320)	(0.00312)	(0.00388)	(0.00421)	(0.00590)
岗位控制变量	Yes	Yes	Yes	Yes	Yes	Yes
年月-城市固定效应	Yes	Yes	Yes	Yes	Yes	Yes
职业固定效应	Yes	Yes	Yes	Yes	Yes	Yes
观测值	1,235,891	208,671	232,448	61,944	94,735	22,690
R 方	0.760	0.751	0.751	0.772	0.792	0.767
被解释变量均值	0.400	0.552	0.515	0.646	0.501	0.676

表 8 从工作经历维度看，求职者是否具备高暴露岗位的经验，也影响其在技术冲击下的过渡方式。对于曾经在高暴露职业中工作过的求职者而言，岗位技能重构带来的替代压力更为直接。这类求职者的向下投递比例显著高于无高暴露经历者，纵向错配也相应上升。这一模式表明：岗位任务结构的变化不仅对当前岗位构成冲击，也对既有的人力资本存量提出新的要求，使原有技能难以完全适应新的任务组合，从而导致这些求职者在职业梯度上出现“向下迁移”。

相比之下，不具备高暴露经历的求职者受岗位专业化提升的限制较弱，更可能选择或转向低暴露职业或技能门槛较低的轨道，因此其向下投递与错配变动较为温和。这一差异进一步说明：技术冲击强化了技能与岗位需求之间的匹配要求，使求职者的相对位置更依赖其技能的可迁移性与与技术互补的能力。

总之，求职者本身的应对能力和应对策略也是造就市场错配形势的原因。在技术冲击带来的岗位专业化与技能复杂化背景下，掌握科学技术相关的专业背景、有与新技术互补的工作经验等，都能使求职者更灵活地调整自己的求职行为，避免陷入高才低就的窘境。而非科技专业背景的求职者可能短期难以充分利用新技术提高自己的生产率，工作经验限于高暴露职业的申请者则受到了更直接的技术替代冲击，他们在短期不得不进行更多的向下投递、经历更严峻的纵向错配问题。

综上所述，第四章的分析揭示了技术冲击如何在岗位与求职者两端共同作用，从而形成“总体错配上升而高暴露职业错配下降”的结构性结果。一方面，企业

在技术冲击后对高暴露岗位进行了系统性的任务与技能重构，使岗位要求呈现更高的复杂度与专业性，从而提高了招聘信号的清晰度和岗位的筛选能力。这一变化抬升了高技能岗位的准入门槛，并削弱了原本依赖信息不对称而进入高暴露职业的“机会性投递”，导致高暴露职业内部的纵向错配显著下降。另一方面，求职者的投递策略也相应调整，中技能岗位成为高学历求职者的主要承接层，而低技能岗位因技能回报低而被高学历群体主动避开。

求职者层面的异质性进一步强化了这一机制链条。技能可迁移性强、与新技术互补性高的求职者（如 STEM 专业）能够适应岗位专业化提升的要求，在高技能轨道中保持相对优势；而非 STEM 群体以及高暴露经历的求职者更容易受到岗位技能重构的直接挤压，在职业结构中出现被迫向下的流动。

七、总结与建议

本文立足于人工智能技术（尤其是大语言模型）深度重塑劳动力市场的时代背景，以 2021 年 1 月至 2025 年 7 月智联招聘平台百万条“岗位-求职者”匹配数据为基础，从基于学历的纵向维度与基于专业的横向维度，系统探究了 AI 时代中国劳动力市场错配的趋势特征、异质性分布，并在张丹丹等（2025）的基础上优化了“大语言模型人工智能技术暴露度”（AI-LLM 暴露指数）的构建方法，研究市场错配与职业暴露度之间的关联，为理解技术变革下的劳动力市场结构性矛盾提供新的实证依据。研究的核心内容可概括为以下三个方面：

其一，市场错配趋势呈双向上升且水平高企。样本期内，中国劳动力市场纵向错配平均比例达 59.9%，从 2021 年的 52.0%逐年增长到 2025 年的 64.9%；横向错配平均比例为 45.1%，经历了从 40.7%的最低值增长到 49.3%的最高值，反映出 AI 驱动的需求端技能重构与供给端规模扩张之间的适配矛盾持续加剧，人力资源配置效率面临挑战。

其二，高暴露度职业在新一轮技术冲击下，总体显示出更低的错配；但总量的背后隐藏着显著的群体异质性：低技能、高暴露职业显示出更低的纵向错配并主导全市场结果；但中高技能岗位的劳动力纵向错配问题在加剧。

其三，我们发现求职者和企业端都在主动调整策略，应对新的技术环境。有科学技术背景、工作经历与新技术互补的求职者掌握更多的调整主动权，因而受到的影响更小；企业在录用新的高暴露度职业岗位时，也会通过更为精准的需求

信号与不断提升的技能复杂度，努力减少了向下投递与纵向错配比例，希望促成纵向适配的市场均衡。

基于上述研究结论，为缓解 AI 时代劳动力市场结构性错配、提升就业质量与资源配置效率，本文从政策端、教育端、求职者端提出三维度建议，具体如下：

教育端，建立教育供给与市场需求的动态对接机制。优化高校专业设置，对高暴露度职业（如计算机、电气工程），扩大相关专业招生规模；增设“AI+专业”交叉课程；对低暴露度但需求稳定的职业，强化“职业特定技能”培养，减少跨领域求职导致的横向错配；同时建立“专业调整预警机制”，对连续三年横向错配率超过阈值的专业进行缩减或转型。此外，缓解层级性错配。针对大专学历群体，聚焦“应用型技能”培养，与高暴露度职业企业共建实训基地，减少“高不成低不就”的跨专业投递；针对本科及以上学历，强化“AI 协同能力”，将大语言模型应用、数据思维纳入通识课程，避免“学历过剩”与“技能不足”并存的纵向错配。

政策端，建立劳动力市场错配与职业暴露度动态监测机制。依托头部在线招聘平台数据，监测不同群体的错配趋势，为教育调整与就业引导提供数据支撑；同时将 AI-LLM 暴露度纳入职业分类标准，明确高暴露度职业（如计算机、金融、医疗）的技能需求清单，引导劳动力流向供需适配领域。此外，实施差异化就业支持政策，聚焦错配高发群体。在短期，非科技专业、专用人力资本受冲击大的求职者，可能受到更严峻的就业冲击，相关政策应当对这一群体持续关注支持；并尝试通过培训等方式提高其对新市场环境的调整适应能力。

就求职者个体而言，应理性评估职业适配性，积极自我适应；不断提升技能，增强适配竞争力，避免长期错配导致的“疤痕效应”。在人工智能技术持续渗透的背景下，劳动力市场错配本质是“技术变革速度”与“人力资本调整速度”的差距问题。唯有通过政策引导、教育改革与个体适配的三方协同，才能将技术挑战转化为就业质量提升的机遇，实现劳动力市场从“规模扩张”向“效率优化”的转型，为中国经济高质量发展提供坚实的人力资源支撑。

参考文献

[1] Abel, J. R., and Deitz, R. (2015). Agglomeration and job matching among college graduates. Regional Science and Urban Economics, 51, 14–24.

[2] Acemoglu, D., and Autor, D. H. (2011). Skills, tasks and technologies: Implications for employment and earnings. Handbook of Labor Economics, 4(B), 1043–1171.

[3] Acemoglu, D., and Restrepo, P. (2019). Automation and new tasks: how technology displaces and reinstates labor. Journal of Economic Perspectives, 33(2), 3–30.

[4] Aufiero, S., De Marzo, G., Sbardella, A., and Zaccaria, A. (2024). Mapping job fitness and skill coherence into wages: an economic complexity analysis. Scientific Reports, 14(1), 11752.

[5] Autor, D. H. (2015). Why are there still so many jobs? The history and future of workplace automation. Journal of Economic Perspectives, 29(3), 3–30.

[6] Autor, D. H., and Dorn, D. (2013). The growth of low-skill service jobs and the polarization of the US labor market. American Economic Review, 103(5), 1553–1597.

[7] Autor, D. H., Levy, F., and Murnane, R. J. (2003). The skill content of recent technological change: An empirical exploration. The Quarterly Journal of Economics, 118(4), 1279–1333.

[8] Béduwé, C., and Giret, J. F. (2011). Mismatch of vocational graduates: What penalty on French labour market?. Journal of Vocational Behavior, 78(1), 68-79.

[9] Bender, K. A., and Heywood, J. S. (2011). Educational mismatch and the careers of scientists. Education Economics, 19(3), 253–274.

[10] Bender, K. A., and Roche, K. (2013). Educational mismatch and self-employment. Economics of Education Review, 34, 85–95.

[11] Bommasani, R., Hudson, D. A., Adeli, E., Altman, R., Arora, S., von Arx, S., … and Liang, P. (2021). On the opportunities and risks of foundation models. arXiv preprint arXiv:2108.07258.

[12] Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., … and Amodei, D. (2020). Language models are few-shot learners. Advances in Neural Information Processing Systems, 33, 1877–1901.

[13] Brynjolfsson, E., and McAfee, A. (2014). The Second Machine Age: Work, Progress, and Prosperity in a Time of Brilliant Technologies. New York: W. W. Norton and Company.

[14] Brynjolfsson, E., and Mitchell, T. (2017). What can machine learning do? Workforce implications. Science, 358(6370), 1530–1534.

[15] Duncan, G. J., and Hoffman, S. D. (1981). The incidence and wage effects of overeducation. Economics of Education Review, 1(1), 75–86.

[16] Eckaus, R. S. (1964). Economic criteria for education and training. The Review of Economics and Statistics, 181–190.

[17] Eloundou，T.，Manning，S.，Mishkin，P. and Rock，D. (2024). GPTs are GPTs：Labor Market Impact Potential of LLMs. Science，384（6702），pp.1306~1308.

[18] Felten, E., Raj, M., and Seamans, R. (2021). Occupational, industry, and geographic exposure to artificial intelligence: A novel dataset and its potential uses. Strategic Management Journal, 42(12), 2195–2217.

[19] Frank, R. H. (1978). Why women earn less: The theory and estimation of differential overqualification. The American Economic Review, 68(3), 360–373.

[20] Frey, C. B., and Osborne, M. A. (2017). The future of employment: How susceptible are jobs to computerisation?. Technological Forecasting and Social Change, 114, 254–280.

[21] Giuntella, O., Lu, Y., and Wang, T. (2025). How do workers adjust to robots? Evidence from China. The Economic Journal, 135(666), 637–652.

[22] Goos, M., and Manning, A. (2007). Lousy and lovely jobs: The rising polarization of work in Britain. Review of Economics and Statistics, 89(1), 118–133.

[23] Green, C., Kler, P., and Leeves, G. (2007). Immigrant overeducation: Evidence from recent arrivals to Australia. Economics of Education Review, 26(4), 420–432.

[24] Hampole, M., Papanikolaou, D., Schmidt, L.D.W., and Seegmiller, B. (2025). Artificial Intelligence and the Labor Market. NBER Working Paper 33509.

[25] Hartog, J. (2000). Over-education and earnings: where are we, where should we go?. Economics of Education Review, 19(2), 131–147.

[26] Kuhn, P., and Shen, K. (2013). Gender discrimination in job ads: Evidence from China. The Quarterly Journal of Economics, 128(1), 287–336.

[27] Manuel, N. (2024). The use of major-related knowledge by early career college graduates. Applied Economics, 56(55), 7302–7316.

[28] Manuel, N., and Plesca, M. (2020). Skill transferability and the earnings of immigrants. Canadian Journal of Economics/Revue canadienne d'économique, 53(4), 1404–1428.

[29] McGuinness, S. (2006). Overeducation in the labour market. Journal of Economic Surveys, 20(3), 387–418.

[30] OECD. (2017). Getting Skills Right: Spain. Paris: OECD Publishing. http://dx.doi.org/10.1787/9789264282346-en

[31] Robst, J. (2007). Education and job match: The relatedness of college major and

work. Economics of Education Review, 26(4), 397–407.

[32] Somers, M. A., Cabus, S. J., Groot, W., and van den Brink, H. M. (2019). Horizontal mismatch between employment and field of education: Evidence from a systematic literature review. Journal of Economic Surveys, 33(2), 567–603.

[33] Tacchella, A., Cristelli, M., Caldarelli, G., Gabrielli, A., and Pietronero, L. (2012). A new metrics for countries' fitness and products' complexity. Scientific Reports, 2(1), 723.

[34] Tsai, Y. (2010). Returns to overeducation: A longitudinal analysis of the US labor market. Economics of Education Review, 29(4), 606–617.

[35] Verdugo, R. R., and Verdugo, N. T. (1989). The impact of surplus schooling on earnings: Some additional findings. Journal of Human Resources, 629–643.

[36] Verhaest, D., and Omey, E. (2006). The impact of overeducation and its measurement. Social Indicators Research, 77(3), 419–448.

[37] Webb，M.，(2020).The Impact of Artificial Intelligence on the Labor Market. SSRN Working Paper 3482150.Available at：https://ssrn.com/abstract=3482150.

[38] Wolbers, M. H. (2003). Job mismatches and their labour-market effects among school-leavers in Europe. European Sociological Review, 19(3), 249–266.

[39] 北京大学国家发展研究院 AI 与经济学实验室，智联招聘. (2025).中国"人工智能-大语言模型技术"暴露指数构建方法与数据说明，v2025.09

[40] 陈媛媛, 张竞，周亚虹. (2022). 工业机器人与劳动力的空间配置. 经济研究, 57(01), 172–188. https://doi.org/CNKI:SUN:JJYJ.0.2022-01-014.

[41] 李骏. (2016). 中国高学历劳动者的教育匹配与收入回报. 社会, 36(03), 64–85. https://doi.org/10.15992/j.cnki.31-1123/c.2016.03.003.

[42] 李磊, 王小霞，包群. (2021). 机器人的就业效应：机制与中国经验. 管理世界, 37(09), 104–119. https://doi.org/10.19744/j.cnki.11-1235/f.2021.0140.

[43] 李晓光. (2024). 教育失配经历对企业雇佣决策的影响：来自简历投递实验和在线招聘职位的证据. 管理世界, 40(04), 121–145. https://doi.org/10.19744/j.cnki.11-1235/f.2024.0039.

[44] 李晓光, 陆瑶, 吴晓刚. (2023). 高学历劳动者的教育失配. 教育研究, 44(06), 122–137. https://doi.org/CNKI:SUN:JYYJ.0.2023-06-010.

[45] 刘云波. (2019). 教育错配和技能错配的发生率及其收入效应——基于中国 CGSS2015 的实证分析. 东岳论丛, 40(03), 60–68. https://doi.org/10.15981/j.cnki.dongyueluncong.2019.03.007.

[46] 谢尚, 韦东明，唐琦. (2024). 互联网使用对教育—工作匹配的影响——基于 CFPS2016 ～ 2020 的研究发现. 中国人口科学, 38(04), 36–51. https://doi.org/CNKI:SUN:ZKRK.0.2024-04-008.

[47] 王林辉, 钱圆圆, 宋冬林，董直庆. (2023). 机器人应用的岗位转换效应及就业敏感性群体特征——来自微观个体层面的经验证据. 经济研究, 58(07), 69–85. https://doi.org/CNKI:SUN:JJYJ.0.2023-07-003.

[48] 王永钦，董雯. (2020). 机器人的兴起如何影响中国劳动力市场?——来自制造业上市公司的证据. 经济研究, 55(10), 159–175. https://doi.org/CNKI:SUN:JJYJ.0.2020-10-011.

[49] 闫雪凌, 朱博楷，马超. (2020). 工业机器人使用与制造业就业: 来自中国的证据. 统计研究, 37(01), 74–87. https://doi.org/10.19343/j.cnki.11-1302/c.2020.01.006.

[50] 张丹丹, 于航, 李力行, 胡佳胤, 莫怡青, 李泓宇. (2025). 中国人工智能技术暴露度的测算及其对劳动需求的影响——基于大语言模型的新证据. 管理世界, 41(07), 59–75. https://doi.org/10.19744/j.cnki.11-1235/f.2025.0092.